

Segmentation, étiquetage morpho-syntaxique et reconnaissance d'entités nommées

Où en sommes-nous dans le pipeline ?

- * Chapitres 1 à 4 : transcription HTR brute → texte normalisé et lisible
- * Il reste non structuré : il faut en extraire des unités linguistiques et des entités

Une entité nommée réfère à un objet du monde : personne, lieu, institution, date — directement exploitable pour des bases de connaissances.

Difficultés propres aux langues historiques

Segmentation

Espaces manuscrits irréguliers, frontières de mots mal restituées par le HTR

Rareté des données annotées

Très peu de corpus médiévaux annotés en POS et en NER

PARTIE 1

Le problème de la segmentation en mots sur manuscrits

Pourquoi les espaces sont irréguliers

- * Le HTR ne voit pas des mots, mais des pixels
- * L'espace est décidé au décodage, selon la largeur de l'écart entre deux formes
- * Les scribes n'avaient pas de règle typographique : l'espacement varie selon la vitesse d'écriture, l'encre, le support

Trois erreurs de segmentation fréquentes

Fusion (merge)

« leseigneur » au lieu de « le seigneur »

Coupure spurieuse

« nor mandie » au lieu de « normandie »

Tiret résiduel

« nor- » / « mandie » dus aux coupures de fin de ligne

Le cas le plus piégeux : clitiques + entité

La fusion d'une préposition ou d'un article devant un nom propre

« *dunormand* » → « *du normand* »

Si la fusion n'est pas corrigée, l'entité nommée « Normand » devient invisible pour le pipeline NER.

Deux métriques pour évaluer la segmentation

TBA (Token Boundary Accuracy)

Fraction des frontières de mots correctement identifiées

TER (Token Error Rate)

Analogue au CER, mais sur les tokens : une fusion compte comme substitution + suppression

Évaluation sur 100 tokens annotés manuellement, en double annotation (sert aussi pour l'IAA, partie 5).

Approche par règles

Déterministe, traçable — la baseline naturelle

- * Suite d'expressions régulières : normalise les espaces, sépare les clitiques, gère les cas spéciaux
- * Suffisante pour un corpus homogène

```
# Tirets résiduels de coupure de ligne
text = re.sub(r'\s+', '', text) # "nor- mandie" -> "normandie"
return text.split()
```

Approche CRF : généraliser au-delà des règles

- * Un CRF prédit, pour chaque position du texte, si c'est une frontière de mot
- * Avantage : généralise depuis des exemples annotés, y compris pour des cas non couverts par les règles
- * Utilise des traits contextuels : caractère, bigrammes voisins, position début/fin

Coût algorithmique du CRF

$$\text{Coût} = O(n \cdot T^2)$$

- * n = longueur de la séquence, T = nombre d'étiquettes
- * Pour la segmentation binaire (frontière / non), $T=2 \rightarrow$ coût quasi linéaire

Pour la NER (partie 3), T peut atteindre 21 avec le schéma BIOES — le coût quadratique en T redevient significatif.

PARTIE 2

Étiquetage morpho-syntaxique (POS-tagging) et lemmatisation

Pourquoi la morphologie médiévale est difficile

- * Cas sujet (li roys) vs cas régime (le roi) : étiquettes POS identiques (DET+NOUN), mais propriétés morphologiques différentes
- * Lemmatisation : venoit, venait, vint, venu, venans doivent tous remonter au lemme venir

Les modèles entraînés sur le français moderne échouent systématiquement sur ces formes médiévales.

pie-extended : l'outil de référence

- * Architecture Pie (Probabilistic Iterative Enumerator) — séquence-à-séquence pour langues morphologiquement riches
- * Modèle medieval-fr entraîné selon le schéma Cattex (étiquettes spécialisées pour le moyen français)

```
pipeline = ExtensiblePipeline.from_pretrained("medieval-fr")
result = pipeline.annotate("le sénéchal porta les lettres")
# -> liste de (forme, lemme, pos, morph)
```


Stanza : deux modèles, une différence cruciale

fro — vieux français

XIe-XIIIe siècle, entraîné sur SRCMF

frm — moyen français

XIVe-XVe siècle, entraîné sur l'Arboratoire — votre corpus

Utiliser fro sur un texte du XVe siècle produit des erreurs systématiques sur les articles et l'imparfait. frm est le bon choix.

fro vs frm : ce qui change vraiment

Caractéristique	fro (vieux fr.)	frm (moyen fr.)
Déclinaison à 2 cas	Très présente	Traces résiduelles
Négation	ne seul fréquent	ne...pas s'impose
Article défini	li, lo, la, les	le, la, les dominant
Morphologie verbale	Désinences latines	Formes en -oit/-ait

Universal Dependencies : un cadre commun

- * UPOS : 17 catégories universelles (NOUN, VERB, ADJ, DET, PROPN...)
- * XPOS : étiquette spécifique à la langue (Cattex pour le moyen français)
- * Feats : traits morphologiques clé-valeur, ex. Number=Sing|Case=Nom|Gender=Masc
- * Head / DepRel : dépendance syntaxique

Le format CoNLL-U

Format d'export standard pour l'annotation UD

```
1 li    le    DET  DArti Case=Nom|Gender=Masc 2 det
2 sénéchal sénéchal NOUN NOMcom Gender=Masc|Number=Sing 3 nsubj
3 porta  porter VERB  VERcjg Mood=Ind|Tense=Past  0 root
```

La colonne 10 (Misc) pourra encoder le polygon_ref — la connexion avec le data contract du Volet 1.

Évaluer le POS-tagging

POS Accuracy = (tokens corrects) / (tokens totaux)

≈ 90 %

Sur textes médiévaux propres — résultat typique pour pie-extended

≈ 82-85 %

Sur HTR brut à CER 10 %, à cause des mots mal orthographiés

PARTIE 3

Schémas d'annotation pour la NER

Le schéma BIO

Une étiquette par token

B-TYPE

Premier token d'une entité

I-TYPE

Token intérieur d'une entité

O

Token hors d'une entité

Pour 5 types d'entités médiévales (PER, LOC, DATE, ORG, TITLE) : $2 \times 5 + 1 = 11$ étiquettes.

Le schéma BIOES : deux étiquettes en plus

E-TYPE

Dernier token d'une entité multi-tokens

S-TYPE

Entité d'un seul token

Pour les mêmes 5 types : $4 \times 5 + 1 = 21$ étiquettes.

BIO vs BIOES sur un exemple

« *le seigneur jean de normandie envoya ses chevaliers* »

BIO : seigneur B-TITLE jean B-PER de I-PER normandie I-PER

BIOES : seigneur S-TITLE jean B-PER de I-PER normandie E-PER

BIOES distingue un token qui constitue l'entité à lui seul (S) du dernier token d'une entité plus longue (E).

Quel schéma choisir ?

- * BIOES aide le décodage des entités mono-token (gain de F1 de 0.5 à 2 points)
- * Pour vos corpus, TITLE et DATE sont souvent mono-token (« seigneur », « mars »)

BIOES est recommandé pour ce corpus, au prix d'un vocabulaire d'étiquettes plus large.

Entités nichées : un cas avancé

« le roi de France Jean II »

- * BIO et BIOES ne gèrent qu'une seule couche d'annotation
- * Ici, l'entité PER « Jean II » est nichée dans une entité composite incluant son titre

Des extensions existent (multi-label BIO, modèles de span à plusieurs niveaux) mais ce cas n'est pas dans le périmètre du Chapitre 6.

PER — Personnes

Spécificités médiévales

- * Le prénom seul suffisait souvent (« li roys » = le roi en exercice)
- * Pas de patronymes : identification par prénom + titre + lieu d'origine
- * Variantes graphiques nombreuses (« Jehan », « Gilles », « Guill^eme »)

LOC — Lieux

Une catégorie particulièrement difficile

- * Beaucoup de noms médiévaux n'ont pas d'équivalent moderne, ou n'existent plus
- * « le chastel de Gisors » = « le château de Gisors », mais certains noms restent ambigus
- * Confusion fréquente avec ORG pour les lieux institutionnels (« la cour de Paris »)

DATE — Dates

Des conventions distinctes du calendrier moderne

- * « en l'an de grâce mil trois cent quarante-six » doit être normalisé en forme structurée
- * Les fêtes religieuses sont des repères temporels (« à la Saint-Jean », « après Pâques »)
- * Leur résolution nécessite le calendrier liturgique

ORG et TITLE

ORG — Organisations

Institutions, chapitres, abbayes, parlement. Frontière floue avec LOC (« l'abbaye de Saint-Denis »)

TITLE — Titres

sénéchal, prévôt, bailli, châtelain, seigneur. Confusion TITLE/PER : l'erreur la plus fréquente

PARTIE 4

Architecture du modèle

Classification de tokens avec BERT

Le problème de l'alignement subword

- * CamemBERT découpe les mots en subwords BPE : « seneschal » → s + ##enes + ##chal
- * L'annotation NER s'applique au mot, pas au subword — il faut réconcilier les deux niveaux

Deux stratégies existent pour répartir l'étiquette du mot sur ses subwords.

Stratégie first-token (recommandée)

- * Seul le premier subword d'un mot reçoit l'étiquette NER
- * Les subwords suivants reçoivent l'étiquette spéciale -100, ignorée par la fonction de perte
- * Simple, et produit de bons résultats en pratique

Stratégie majority vote

- * L'étiquette est prédite pour chaque subword
- * Le mot reçoit l'étiquette majoritaire parmi ses subwords
- * Plus coûteuse, utile quand le radical porteur de sens est en milieu de mot

Aligner les étiquettes : le code

```
for word_id in word_ids:
    if word_id is None:      # [CLS], [SEP]
        labels.append(-100)
    elif word_id != prev_word_id: # premier subword
        labels.append(orig_labels[word_id])
    else:                    # subword suivant
        labels.append(-100)   # stratégie "first"
```

La couche de sortie : softmax

$$\hat{y}_t = \text{softmax}(W \cdot h_t + b)$$

- * h_t : représentation du token t produite par CamemBERT (dimension 768)
- * Chaque token est classé indépendamment des autres

Limite : la softmax peut produire des séquences incohérentes, par exemple I-PER juste après B-LOC.

La couche CRF : modéliser les transitions

$$score = \sum P_t[y_t] + \sum A[y_t, y_{t+1}]$$

- * A est une matrice de transitions apprise entre étiquettes consécutives
- * Le décodage trouve la séquence de score maximal — algorithme de Viterbi, en $O(n \cdot T^2)$

CRF : un coût négligeable, un gain réel

Coût mémoire

T^2 paramètres en plus — $\sim 0.0001\%$ de CamemBERT (110M params)

Gain de F1

+0.5 à 1.5 points vs softmax, surtout pour entités multi-tokens

Pour un corpus médiéval avec entités longues (lieux composés, titre+prénom), la couche CRF est recommandée.

CamemBERT face au moyen français

Deux limites

Subwords peu informatifs

« sénéchal » → s + ##én + ##échal — représentation diluée

Co-occurrences décalées

« seigneur » en contexte religieux moderne ≠ noble local dans vos chartes

Stratégie : le fine-tuning LoRA (Chapitre 3) apprend les représentations médiévales sans modifier tous les poids — détaillé au Chapitre 6.

PARTIE 5

Mesure de l'accord inter-annotateurs (IAA)

Pourquoi l'IAA est obligatoire

- * Une référence n'est fiable que si les annotateurs humains s'accordent entre eux
- * Si deux experts ne s'accordent qu'à 70 %, un modèle à 80 % n'est pas forcément meilleur — il peut être biaisé vers un annotateur

Si le kappa entre deux annotateurs est < 0.7 , les consignes sont ambiguës et doivent être précisées avant d'annoter davantage.

Le kappa de Cohen

Mesure l'accord au-delà du hasard

$$\kappa = (p_o - p_e) / (1 - p_e)$$

- * p_o : accord observé entre les deux annotateurs
- * p_e : accord attendu par le simple hasard

Un exemple chiffré sur 100 tokens

- * Annotateur A : 50 O, 25 B-PER, 25 autres
- * Annotateur B : 52 O, 24 B-PER, 24 autres
- * Accord observé : 85/100 $\rightarrow p_o = 0.85$, et $p_e \approx 0.375$

$$\kappa = (0.85 - 0.375) / (1 - 0.375) \approx 0.76$$

Interpréter le kappa

Kappa	Interprétation
< 0.20	Accord médiocre — consignes à retravailler
0.21 – 0.40	Accord passable
0.41 – 0.60	Accord modéré
0.61 – 0.80	Accord substantiel — acceptable pour une référence
> 0.80	Accord presque parfait

Objectif raisonnable pour une première session d'annotation NER médiévale : $\kappa \approx 0.70$.

Le problème de la classe O

- * 70 à 85 % des tokens sont hors entité (O)
- * Cela gonfle artificiellement p_e et rend le kappa moins discriminant sur les entités

Kappa pondéré

Pondère les désaccords selon leur gravité

Macro-kappa par type

Kappa calculé par type d'entité, en excluant O

PARTIE 6

Propagation d'erreurs HTR → NER

La question : CER dégrade-t-il le F1-NER ?

- * Les erreurs de transcription HTR se propagent à toutes les couches d'analyse NLP
- * La relation n'est pas uniforme selon le type d'entité

C'est une question quantitative : il faut la mesurer, pas la supposer.

Robustesse selon le type d'entité

LOC / DATE — robustes

« Normndie » reste reconnaissable malgré des erreurs de caractères

PER — fragile

Prénoms rares (« Enguerrand ») souvent des hapax, sensibles à 1 substitution

TITLE — intermédiaire

Reconnu par co-occurrence syntaxique stable (« le [TITLE] de [LOC] »)

Simuler la dégradation

Injection d'erreurs de type HTR dans un texte de référence

- * Substitution de caractère (60%), insertion (20%), suppression (20%)
- * Proportions typiques d'un modèle HTR réel

```
n_errors = int(len(chars) * cer)
op = rng.choices(['sub','ins','del'], weights=[0.6,0.2,0.2])[0]
# ... applique l'opération à une position aléatoire
```


CER → F1-NER : la table de référence

CER HTR	F1-NER estimé	Dégradation
0 % (parfait)	0.820	—
5 %	0.745	−9.1 %
10 %	0.670	−18.3 %
12 %	0.640	−22.0 %

Basé sur Hamdi et al. (2021), extrapolé pour textes médiévaux.

La leçon pratique

- * Passer de CER 12 % à CER 5 % récupère environ 13 points de F1-NER
- * Ce gain est obtenu en améliorant le HTR ou en appliquant la normalisation du Jour 2

C'est la justification quantitative de l'ordre des étapes du pipeline : normaliser avant d'extraire des entités.

Le rôle du pipeline de normalisation

- * Les Chapitres 3 et 4 ne servent pas qu'à la lisibilité du corpus
- * En réduisant le CER de 12 % à 5-7 % (valeur typique après règles + cache DMF), le F1-NER s'améliore mécaniquement

C'est la justification quantitative de l'ordre des étapes dans votre pipeline de traitement.

PARTIE 7

Point éthique : biais de représentation en NER

Des corpus construits par des choix éditoriaux

- * Quels documents conserver, numériser, annoter — ces choix créent des biais systématiques
- * Ces biais se transmettent aux modèles NER entraînés sur ces corpus

Trois biais principaux : classe sociale, géographie, genre.

Biais de classe sociale

- * Chartes, registres de compte, rôles fiscaux : quasi exclusivement noblesse, clergé, bourgeoisie urbaine
- * Les personnes de condition servile ou paysanne apparaissent peu, et comme objets d'actes plutôt qu'agents

Un modèle entraîné sur ce corpus reconnaîtra bien comtes et évêques, moins bien artisans et vilains.

Biais géographique et de genre

Géographique

Corpus concentrés sur Île-de-France, Normandie, Bourgogne — dialectes régionaux sous-représentés

Genre

Scripteurs presque exclusivement masculins — prénoms féminins sous-représentés dans les entités PER

Conséquences sur le modèle

- * F1 élevé sur les entités fréquentes (nobles masculins, lieux d'Île-de-France)
- * F1 bas sur les entités rares (femmes, paysans, lieux périphériques)
- * Risque de biais de confirmation si le modèle alimente une base de connaissances

Trois stratégies de mitigation

Stratification de l'annotation

Couvrir différents types de documents, régions, périodes — pas seulement les lignes faciles

Augmentation ciblée

Exemples synthétiques pour les types d'entités sous-représentés

Rapport d'erreurs stratifié

F1 par type d'entité et par sous-corpus (document, région, date)

Pour aller plus loin

Quelques repères bibliographiques

POS & lemmatisation médiévale

Camps et al. (2021), pie-extended ; Qi et al. (2020), Stanza ; Nivre et al. (2016), Universal Dependencies

NER

Lample et al. (2016), LSTM-CRF ; Devlin et al. (2019), BERT ; Martin et al. (2020), CamemBERT

Biais et éthique

Bender et al. (2021), Stochastic Parrots ; Jørgensen et al. (2016), biais socio-démographiques