

Pipeline NER bout en bout sur le corpus médiéval

De la théorie à la production

- * Le Chapitre 5 a posé les fondements : BIO/BIOES, CamemBERT+CRF, kappa, propagation HTR
- * Ce TP construit le pipeline complet : transcriptions normalisées → corpus annoté NER, POS, lemmes

Sortie : formats standards des humanités numériques — CoNLL-2003, CoNLL-U, data contract enrichi.

Quatre décisions structurantes

1. Données normalisées, pas brutes

CER 12% → 5% récupère ~13 points de F1-NER (Ch. 5)

2. CamemBERT + LoRA

Pas de full fine-tuning — mémoire et sur-apprentissage

3. Outils distincts pour POS/lemmes

pie-extended et Stanza frm, pas le modèle NER

4. Data contract enrichi

polygon_ref maintient le lien avec le Volet 1

PARTIE 1

Stratégie de données

Constituer le corpus d'entraînement NER

Trois artefacts issus des étapes précédentes

split_manifest.json

Identifie train/val/test — garantit la comparabilité avec le tableau d'ablation

Corpus normalisé

Sortie règles + DMF + mT5-LoRA (ou règles seules, CER $\approx$ 4-5 %)

journal.jsonl

Trace quel modèle de normalisation a produit les données d'entraînement

Bootstrap par gazetier

Supervision faible pour amorcer l'annotation

- * Annoter 200 lignes à la main prend 2 à 3 heures pour un expert
- * Une liste d'entités connues annote automatiquement le corpus ; un humain corrige ensuite

La pré-annotation par gazetier réduit le coût d'annotation humaine d'environ 40 % — elle ne le remplace pas.

Le gazetier minimal

```
GAZETTEER = {  
  'PER': {'jean', 'pierre', 'guillaume', ...},  
  'LOC': {'normandie', 'paris', 'rouen', ...},  
  'DATE': {'janvier', 'pâques', 'noël', ...},  
  'ORG': {'parlement', 'abbaye', 'cour', ...},  
  'TITLE': {'seigneur', 'sénéchal', 'roi', ...},  
}
```

Conflits résolus par priorité décroissante : TITLE > PER > ORG > LOC > DATE.

Limites du gazetier

- * Ne couvre pas les entités multi-tokens (« jean de normandie »)
- * Ne couvre pas les variantes graphiques non normalisées (« Jehan », « Guillaumes »)

C'est précisément pour corriger ces cas que l'annotation humaine reste indispensable.

Le format CoNLL-2003

Format d'interchange standard pour la NER

```
-DOCSTART- -X- O O  
  
li      DET  _  O  
sénéchal NOUN _  B-TITLE  
jean    PROPN _  B-PER  
de      ADP  _  I-PER  
normandie PROPN _ I-PER
```

4 colonnes : forme, POS, chunk tag (souvent _), étiquette NER. C'est ce format qu'attend segeval.

PARTIE 2

Fine-tuning CamemBERT-NER avec LoRA

L'architecture complète

- * CamemBERT + tête de classification linéaire
- * Adaptateurs LoRA sur les projections Q et V des 12 couches d'attention
- * La tête projette les 768 dimensions vers T étiquettes (T=11 pour BIO, T=21 pour BIOES)

La tête ajoute 8 459 paramètres (0.008 % du modèle) — entraînable en full fine-tuning sans impact mémoire.

Bilan mémoire : LoRA r=8, Q+V

CamemBERT-base, 110M paramètres

Composante	Paramètres	Mémoire
CamemBERT gelé (fp16)	110 000 000	220 Mo
LoRA Q+V, r=8, 12 couches	159 744	0.6 Mo
Adam sur LoRA	159 744	1.3 Mo
Tête de classification	8 459	0.03 Mo
Activations (batch=16)	—	~500 Mo

Total GPU ≈ 722 Mo ≈ 0.7 Go — confortable sur un T4 (16 Go).

Pourquoi LoRA, si la mémoire est confortable ?

- * Le full fine-tuning de CamemBERT requiert ~1.8 Go pour l'optimiseur seul, plus les activations
- * Pour des modèles plus grands, la différence devient dramatique

Le risque de sur-apprentissage sur un corpus annoté limité justifie indépendamment le choix LoRA.

Configuration LoRA pour la NER

```
lora_config = LoraConfig(  
    r=8, lora_alpha=16,  
    target_modules=["query", "value"], # RoBERTa, pas T5  
    lora_dropout=0.1, bias="none",  
    task_type=TaskType.TOKEN_CLS,  
    modules_to_save=["classifier"],  
)
```

task_type=TOKEN_CLS (≠ SEQ_2_SEQ_LM du Chapitre 3) : c'est une classification, pas une génération.

modules_to_save : ne pas perdre la tête

- * `modules_to_save=["classifier"]` indique à PEFT de sauvegarder la tête de classification avec le checkpoint LoRA
- * Sans cette ligne, la tête serait perdue au chargement

target_modules varie selon l'architecture : « query »/« value » pour CamemBERT (RoBERTa), « q »/« v » pour T5/mT5. Toujours vérifier avec `model.named_modules()`.

Pondérer la loss par la confiance HTR

- * Équivalent NER du WeightedSeq2SeqTrainer du Chapitre 3
- * Chaque exemple porte un sample_weight (confiance de la ligne HTR)
- * Les lignes moins fiables contribuent moins à l'entraînement

```
per_seq_loss = (per_token_loss * valid_mask).sum(dim=1) / valid_mask.sum(dim=1)
loss = (per_seq_loss * weights).mean()
```


Une chaîne de traçabilité complète

char_confidences (Volet 1) → confidence (corpus) → sample_weight (NER)

Un pipeline qui ignore cette information traite de façon identique une ligne à 95 % de confiance et une ligne à 62 %.

Hyperparamètres recommandés pour la NER

20 epochs

La NER converge plus lentement : les entités rares sont vues peu souvent

learning rate = $2e-4$

Plus conservateur que pour la normalisation — gradients plus sensibles

Early stopping (patience=5) arrête l'entraînement si le F1 de validation stagne.

PARTIE 3

Annotation POS et lemmatisation

pie-extended et Stanza

pie-extended en pratique

```
tagger = ExtensibleTagger.from_pretrained("medieval-fr")
for token, ann in zip(tokens, tagger.tag_tokens(tokens)):
    # {"form", "lemma", "pos", "morph"}
```

Chaque token reçoit sa forme, son lemme, son étiquette POS (schéma Cattex) et ses traits morphologiques.

Schéma Cattex vs UPOS

Une table de correspondance est nécessaire pour CoNLL-U

```
CATTEX_TO_UPOS = {  
  'NOMcom': 'NOUN', 'NOMpro': 'PROPN',  
  'VERcjg': 'VERB', 'DArti': 'DET',  
  'ADJqua': 'ADJ', 'PRE': 'ADP',  
}
```

pie-extended produit des étiquettes Cattex (NOMcom, VERcjg, DArti) ; l'export CoNLL-U utilise UPOS.

Stanza pour les dépendances syntaxiques

- * pie-extended produit POS et lemme, mais pas les arcs de dépendance
- * Stanza frm complète l'annotation avec les colonnes head et deprel
- * tokenize_pretokenized=True : on fournit les tokens déjà segmentés (Chapitre 5)

CoNLL-U : le format d'échange universel

10 champs séparés par tabulation

```
1 li    le    DET DArti Gender=Masc 2 det _ polygon_ref=bbox_230
2 sénéchal sénéchal NOUN NOMcom Number=Sing 3 nsubj _ _
3 porta  porter VERB VERcjg Tense=Past 0 root _ _
```

La colonne MISC (champ 10) encode le polygon_ref — chaque token est lié à sa position dans le manuscrit numérisé.

Exporter le corpus en CoNLL-U

- * Chaque phrase commence par # sent_id et # text
- * Les ner_spans sont encodés en commentaire (extension non-UD)
- * Le champ MISC reçoit polygon_ref=... s'il est disponible, sinon _

PARTIE 4

Évaluation avec seqeval

Évaluation au niveau span, pas token

- * « jean de normandie » doit être reconnue dans son intégralité (tokens, type, frontières) pour compter comme vrai positif
- * Une entité au bon type mais à frontière incorrecte compte comme faux positif ET faux négatif

segeval est la bibliothèque de référence pour cette évaluation au niveau entité.

Quatre métriques à calculer

```
f1_score(y_true, y_pred, average="micro", scheme=IOB2)  
f1_score(y_true, y_pred, average="macro", scheme=IOB2)  
precision_score(y_true, y_pred, average="micro", scheme=IOB2)  
recall_score(y_true, y_pred, average="micro", scheme=IOB2)
```

classification_report(..., output_dict=True) fournit aussi le détail par type d'entité.

Résultats indicatifs sur ~200 lignes annotées

Entité	Précision	Rappel	F1
PER	0.849	0.789	0.818
LOC	0.925	0.899	0.912
DATE	0.903	0.875	0.889
ORG	0.667	0.562	0.610
TITLE	0.738	0.775	0.756
micro	0.836	0.800	0.818

F1 macro ≈ 0.797 (non pondéré par fréquence)

F1 micro vs macro : toujours reporter les deux

F1 micro

Pèse chaque entité selon sa fréquence — LOC et PER dominant le score

F1 macro

Même poids pour chaque type — ORG et TITLE tirent le score vers le bas

ORG est systématiquement le plus faible

- * Les organisations médiévales partagent leur surface lexicale avec des LOC (« la cour de Paris »)
- * ...et avec des TITLE (« le chapitre » sans nom propre)

La frontière ontologique est ambiguë — c'est une source de désaccord inter-annotateurs avant d'être une limite du modèle.

PARTIE 5

Analyse des erreurs

La matrice de confusion par type d'entité

- * Lignes = type réel, colonnes = type prédit, diagonale = vrais positifs
- * Contrairement à la classification standard, une ligne/colonne O capture entités manquées et faux positifs hors entité

Construite au niveau span via `seqeval.metrics.sequence_labeling.get_entities`.

Erreur n°1 : confusion PER / LOC

- * « Jean de Normandie » : un LOC (Normandie) imbriqué dans une PER
- * BIO ne représente pas l'imbrication — il faut choisir un seul niveau

Convention standard : annoter l'entité de plus haut niveau (PER pour « Jean de Normandie »). Les annotateurs novices l'inversent souvent.

Erreur n°2 : confusion TITLE / PER

- * « le seigneur » sans antécédent désigne une personne par sa fonction
- * Le modèle tend à annoter « seigneur » comme TITLE plutôt que comme référence à une PER

Ce cas est ambigu même pour un expert — il justifie une règle explicite dans les consignes d'annotation.

Erreur n°3 : abréviations résiduelles

- * Si « Guill^me » n'a pas été résolu en « Guillaume », l'entité PER se fragmente
- * Le modèle ne reconnaît pas le token abrégé comme faisant partie de la PER

Chaque abréviation non résolue par le pipeline du Jour 2 est une entité potentiellement manquée — l'importance du pipeline hybride du Chapitre 4.

Erreur n°4 : lieux non répertoriés

- * Micro-toponymes (« le bois de la Croix-aux-Moines », « le marais de Pontoise »)
- * Absents des gazetiers et des données de pré-entraînement de CamemBERT

Ces unseen entities ne peuvent être signalées que par le contexte syntaxique : « le [LOC] de [LOC] ».

L'IAA comme borne supérieure

- * Le kappa inter-annotateurs sert de référence naturelle pour le F1 du modèle
- * Un kappa de 0.76 correspond approximativement à un F1 de 0.82-0.85

Si le modèle atteint $F1 \approx \text{kappa}$, il se comporte comme un annotateur humain — la marge résiduelle relève des cas où les humains eux-mêmes divergent, pas d'un déficit du modèle.

PARTIE 6

Intégration dans le data contract NLP

Le data contract enrichi

Chaque ligne reçoit les annotations du jour

```
{
  "line_id": "charte_1346_fol12_103",
  "normalized": "li sénéchal jean de normandie porta...",
  "ner_spans": [{"start":3,"end":11,"label":"TITLE","text":"sénéchal"}, ...],
  "pos_tags": ["DET","NOUN","PROPN", ...],
  "lemmas": ["le","sénéchal","jean", ...],
  "polygon_ref": "fol12_bbox_230_415_890_440"
}
```

Les invariants à vérifier

- * `pos_tags` et `lemmas` ont exactement la même longueur que `normalized.split()`
- * Les offsets `start/end` de `ner_spans` sont des offsets caractères dans `normalized`, pas des indices de tokens
- * `polygon_ref` reprend la valeur du Volet 1 — il n'est pas recalculé

Construire un enregistrement validé

```
assert len(pos_tags) == len(tokens)
assert len(lemmas) == len(tokens)
for span in ner_spans:
    assert normalized[span['start']:span['end']] == span['text']
```

Ces assertions sont vérifiées avant de retourner l'enregistrement — fail fast plutôt que produire un corpus incohérent.

Écrire et valider le corpus enrichi

- * Format JSONL : une ligne JSON par enregistrement
- * Compatible avec les pipelines Spark, HuggingFace datasets...
- * `validate_corpus()` vérifie les invariants sur tout le corpus et liste les erreurs

Le lien avec le Chapitre 7

ner_spans

Alimentent l'extraction de relations et le graphe de connaissances

lemmas

Permettent d'indexer le corpus par forme canonique

polygon_ref

Assurent la traçabilité jusqu'à l'image source

Condition nécessaire pour que les humanistes vérifient chaque annotation dans le manuscrit original.

PARTIE 7

Point éthique : analyser les biais de représentation

Mesurer les biais sur votre propre corpus

- * Le Chapitre 5 a décrit les sources de biais structurels (classe, géographie, genre)
- * Ce chapitre fournit les outils pour les mesurer concrètement

```
analyze_ner_representation(records)  
# -> distribution par type, ratio PER fém./masc., top-5 LOC
```

Trois indicateurs à calculer

Distribution par type

Combien d'entités de chaque type (PER, LOC, DATE, ORG, TITLE) ?

Ratio PER féminin/masculin

Approximation par liste de prénoms féminins connus

Top-5 LOC

Concentration géographique des lieux mentionnés

Interpréter : > 85 % d'entités PER masculines

- * Ce n'est pas le reflet de la société médiévale
- * C'est le reflet du corpus de chartes, qui documente la noblesse masculine

Un modèle entraîné sur ce corpus sera mécaniquement plus précis sur les personnages masculins.

Interpréter : top-5 LOC > 50 % des occurrences

- * Le modèle reconnaîtra bien Paris, Normandie, Rouen
- * Mais échouera sur les micro-toponymes ruraux

Précisément les lieux qui intéressent les historiens de la vie locale.

Ces constats définissent un domaine de validité

- * Ils ne disqualifient pas le modèle
- * Ils doivent être documentés dans la model card du checkpoint

Un utilisateur appliquant ce modèle à des registres paroissiaux gascons du XVe siècle doit savoir qu'il sort du domaine d'entraînement.

Les livrables attendus en fin de séance

- * Le modèle NER évalué (F1 par catégorie)
- * Le corpus annoté CoNLL-2003
- * La mesure IAA sur 100 lignes
- * Le rapport d'analyse d'erreurs

Pour aller plus loin

Quelques repères bibliographiques

NER et fine-tuning

Lample et al. (2016) ; Devlin et al. (2019), BERT ; Hu et al. (2022), LoRA

Annotation et formats

Tjong Kim Sang & De Meulder (2003), CoNLL-2003 ; Nivre et al. (2020), UD v2

Données et biais

Bender et al. (2021), Stochastic Parrots ; Hamdi et al. (2021)