

Base de connaissances médiévale interrogeable

Chapitre 8

Dernier acte

- * Le Chapitre 7 a posé les principes : BERTopic, extraction de relations, graphe, TEI, JSON-LD, boucle HTR
- * Ce chapitre met ces outils en œuvre sur votre corpus réel

Sur un petit corpus réel, on obtient du bruit et des clusters instables — ce chapitre explique comment lire ces résultats honnêtement.

Le fil conducteur : la traçabilité

- * Chaque affirmation — un topic, un triplet, une coréférence — doit être vérifiable via le polygon_ref

Un graphe de connaissances sans ancrage à la source primaire n'est pas un outil de recherche — c'est une hallucination organisée.

Les huit étapes du TP

1-2. BERTopic & relations

Topics interprétés, triplets PER-LOC-DATE

3-4. Coréférence & graphe

Chaînes d'identité, graphe enrichi JSON-LD

5-6. TEI & interface

Un fichier par acte, index de requête

7-8. Data contract v2 & HTR

Schéma final, fichier de rétroaction

PARTIE 1

Interprétation des topics

BERTopic sur le corpus agrégé

Des lignes aux documents

- * Le data contract du Jour 3 contient des lignes de manuscrit, pas des documents
- * BERTopic a besoin d'unités textuelles assez longues pour que les embeddings capturent la sémantique

Il faut donc agréger les lignes avant d'appliquer BERTopic.

Trois niveaux d'agrégation

Par folio/page

Niveau naturel du manuscrit, souvent hétérogène

Par acte (recommandé)

Un acte = un sujet juridique — topics interprétables

Par lot thématique connu

Validation croisée avec des métadonnées de type documentaire

Agréger par acte

```
key = re.sub(r'_l\d+$', '', line_id) # charte_1346_fol12_103 -> charte_1346_fol12
# Concaténation des lignes du même acte
text = " ".join(r["normalized"] for r in recs)
```

Le document résultant porte aussi les lemmas, ner_spans et line_ids agrégés.

Calibrer HDBSCAN pour un petit corpus

- * `min_cluster_size=10` (défaut) est conçu pour des milliers de documents
- * Sur 40 documents, cette valeur produit un unique cluster de bruit

Pour 40-200 documents : `min_cluster_size=3`, `min_samples=2`, UMAP en 3D avec `n_neighbors=5`.

Configuration calibrée

```
umap_model = UMAP(n_neighbors=5, n_components=3, metric="cosine")
hdbscan_model = HDBSCAN(min_cluster_size=3, min_samples=2)
vectorizer_model = CountVectorizer(stop_words=stop_words_med, min_df=1)

topic_model = BERTopic(embedding_model=embedding_model,
                        umap_model=umap_model, hdbscan_model=hdbscan_model,
                        vectorizer_model=vectorizer_model, nr_topics="auto")
```

Stop words médiévaux étendus : li, lo, lesdits, ledit, ladite, audit, dudit.

Quatre topics typiques : liturgique

- * Mots : abbaye, moine, âme, chapelle, dieu, prière, offrande, fondation
- * Documents : donations religieuses, fondations de messes, testaments pieux
- * Entités dominantes : ORG (abbayes), DATE (fêtes liturgiques)

Le plus facile à identifier — son vocabulaire est lexicalement distinct des autres topics.

Quatre topics typiques : juridique

- * Mots : acte, charte, sceller, témoin, consentir, accord, ratifier
- * Documents : actes de vente, cessions de droits, reconnaissances de dettes
- * Entités dominantes : PER (signataires), TITLE (notaires), DATE

Le plus homogène formellement : les formules juridiques varient peu — cohérent mais peu informatif sur le contenu.

Quatre topics typiques : fiscal

- * Mots : denier, livre, taxe, bailli, lever, rendre, compte, fermage
- * Documents : comptes de bailliage, rôles de taille, quittances
- * Entités dominantes : DATE (exercices fiscaux), LOC (localités), TITLE (baillis)

Le plus hétérogène géographiquement — les lieux varient beaucoup d'un compte à l'autre.

Quatre topics typiques : narratif/politique

- * Mots : roi, guerre, chevalier, armée, siège, victoire, hommage, vassal, fief
- * Documents : chroniques, lettres royales, actes d'hommage féodal

Souvent le plus difficile à isoler : partage du vocabulaire avec les topics juridique (hommage, fief) et nobiliaire.

Évaluer : cohérence c_v

0.40 – 0.55

Fréquent sur corpus court —
ne disqualifie pas le modèle

> 0.50

Topic acceptable

> 0.60

Topic interprétable avec
confiance

Sur corpus court, ces valeurs basses signalent qu'une validation humaine est nécessaire — pas un échec.

Validation par entités nommées

- * Pour chaque topic, vérifier que les entités des documents assignés sont cohérentes avec l'interprétation

Un topic « liturgique » dont les documents ne contiennent que des PER laïcs et aucune ORG religieuse est suspect : le topic est mal nommé, ou des documents sont mal assignés.

PARTIE 2

Extraction de relations simples PER-LOC-DATE

Pourquoi cibler PER-LOC-DATE ?

- * Ces triplets sont les plus fréquents dans les chartes médiévales
- * Les plus utiles pour les historiens : chronologies d'acteurs, réseaux de seigneuries, co-présences

Savoir que « Jean de Normandie » est associé à « Gisors » en « mars 1346 » permet de construire ces structures.

Cinq relations cibles

Relation	Sujet	Objet
réside_à	PER	LOC
porte_titre	PER	TITLE
agit_lors_de	PER	DATE
signe_acte_à	PER	LOC
appartient_à	PER/LOC	ORG

Le prompting few-shot est essentiel

- * Sans exemple, un LLM produit souvent des entités qui ne correspondent pas aux annotations NER
- * Le prompt inclut les entités déjà identifiées par le NER du Jour 3

Sans alignement avec le NER, les triplets sont impossibles à relier au graphe.

Le prompt structuré

Relations cibles : réside_à, porte_titre, agit_lors_de, ...
Entités déjà identifiées : sénéchal (TITLE), normandie (LOC)
Texte normalisé : "li sénéchal jean de normandie..."

Exemple de sortie :
[{"sujet": "Jean de Normandie", "relation": "réside_à",
"objet": "Normandie", "confiance": 0.9}]

Validation manuelle : un triplet est correct si...

- * (a) Sujet et objet correspondent exactement à des spans NER identifiés
- * (b) La relation est du bon type
- * (c) Le triplet est attesté dans le texte source (pas une inférence non textuelle)

Calculer la précision sur 50 triplets

```
sample = rng.sample(relations, 50)
# pour chaque triplet : afficher contexte, NER connu, triplet
# verdict humain : correct ? -> tp ou fp
precision = tp / (tp + fp)
```

Le rappel n'est qu'estimé (~30 % de triplets manqués) : il n'existe pas de référence exhaustive.

Valeurs attendues et erreurs fréquentes

Précision $\approx$ 0.80-0.85

Rappel estimé 0.70-0.80, F1 0.75-0.82

réside_à confus

Confusion entre lieu de l'acte et résidence de la personne

appartient_à manqué

ORG implicites, non mentionnées textuellement

PARTIE 3

Résolution de coréférence sur les entités nommées

Le problème sur corpus multi-actes

« *Jean de Normandie* » (1346), « *Messire Jean* » (1348), « *ledit seigneur* » (1349)

* Même individu — ou trois individus homonymes ?

Seul le contexte historique (dates, lieux, titres associés) permet de trancher.

Deux niveaux de résolution

Intra-acte

Pronoms et anaphores (« ledit seigneur ») → dernière entité de même type — règles du Chapitre 7

Inter-actes

Comparaison des mentions entre documents — entity linking

Construire les chaînes de corréférence

- * 1. Collecter toutes les mentions PER, LOC, ORG
- * 2. Grouper par similarité de texte (SequenceMatcher) et de type
- * 3. Choisir la forme canonique (mention la plus longue et fréquente)

Seuil de similarité par défaut : 0.75.

Regroupement par similarité

```
sim = SequenceMatcher(None, mention.lower(), rep.lower()).ratio()
if sim >= 0.75:
    group.append(mention)
# forme canonique = mention la plus longue du groupe
canonical_text = max(group, key=lambda m: len(m["text"]))["text"]
```

40 phrases → 8 à 15 identités canoniques

- * L'évaluation quantitative (MUC, B³, CEAF) nécessite une référence annotée que vous n'avez pas
- * L'évaluation est donc qualitative

Vérifier que les chaînes sont linguistiquement cohérentes et que les fusions inter-actes sont justifiées.

Deux questions de vérification

- * Compatibilité chronologique : « Jean de Normandie » en 1340 et en 1390 — probablement deux personnes (50 ans d'écart)
- * Cohérence des titres : un même individu ne peut être simultanément « bailli » et « sénéchal » dans des actes contemporains

PARTIE 4

Construction du graphe de connaissances enrichi

Deux enrichissements par rapport au Chapitre 7

Topics BERTopic

Attribut de document, propagé aux entités qu'il contient

Identifiants canoniques

Les chaînes de coréférence fusionnent les nœuds dupliqués

Construire le graphe enrichi

```
# Nœuds canoniques depuis les chaînes de coréférence
G.add_node(cid, label=chain["canonical_text"], type=chain["type"],
           n_mentions=chain["n_mentions"])
# Arêtes via mention_to_canonical (résout vers le nœud fusionné)
G.add_edge(s_id, o_id, relation=rel["relation"],
           confiance=rel.get("confiance", 1.0))
```

Propager les topics aux nœuds

- * Pour chaque ligne, retrouver le doc_id (acte) et ses topics
- * Chaque entité de la ligne reçoit les topics de son acte d'origine

Un nœud mentionné dans plusieurs actes accumule les topics de chacun.

JSON-LD complet : nouveaux attributs

Attribut	Origine
polygon_ref	Ancrage spatial Volet 1
topic_label	Topics BERTopic propagés
n_mentions	Nombre de mentions de la chaîne
tei_ref	Référence vers le fichier TEI de l'acte

Chaque relation sortante est sérialisée avec son score de confiance.

Un nœud JSON-LD complet

```
{
  "@id": "medieval:seigneur_gisors",
  "@type": "TITLE",
  "name": "seigneur",
  "polygon_ref": "foll2_bbox_230_415_890_440",
  "topic_label": ["juridique"],
  "n_mentions": 3,
  "réside_à": {"@id": "medieval:gisors", "confiance": 0.91 }
}
```

PARTIE 5

Export TEI : un fichier par acte

Un fichier par acte, pas par ligne

- * Chaque acte (niveau d'agrégation de l'Étape 1) donne lieu à un fichier XML distinct
- * Chaque document a son propre teiHeader décrivant la source physique

Conforme aux pratiques éditoriales TEI : chaque document est une unité de publication autonome.

Structure d'un fichier TEI par acte

```
{doc_id}.xml
<TEI>
  <teiHeader> <!-- titre, source, idno -->
  <text><body><div type="acte" n="charte_1346_fol12">
    <lb n="..._103" facs="fol12_bbox_230_415_890_440"/>
    <roleName key="seigneur_gisors"><w lemma="seigneur" pos="NOUN">seigneur</w></roleName>
    ...
  </div></body></text>
</TEI>
```


Le lien avec la coréférence dans le TEI

- * Si l'identifiant canonique d'une entité existe dans coref_chains, l'attribut @key le reprend

<roleName key="seigneur_gisors"> relie directement l'occurrence textuelle au nœud du graphe de connaissances.

Exporter tout le corpus

```
# Grouper par acte (même clé que pour BERTopic)
actes = group_by(re.sub(r'_l\d+$', '', line_id))
for doc_id, records in actes.items():
    records_to_tei_file(records, doc_id, output_dir, coref_chains, graph)

# Validation : xmllint --relaxng tei_all.rng --noout output_dir/*.xml
```

PARTIE 6

Interface de requête minimale

Un index en mémoire, pas de base de données

- * Pour un corpus de quelques centaines de lignes, un index Python en mémoire suffit
- * Interrogation en ligne de commande ou dans le notebook — sans déployer de service

Trois index complémentaires

text_index

lemme → line_ids (recherche plein-texte)

entity_index

(texte, type) → line_ids (filtre par entité)

topic_index

topic_id → doc_ids (filtre par topic)

Une interface unifiée par intersection

```
index.query(entity="Normandie", entity_type="LOC", topic_id=1)  
# -> intersection des line_ids correspondant à  
#   text + entity + topic
```

Chaque critère (text, entity, topic_id) restreint l'ensemble de résultats par intersection.

PARTIE 7

Data contract NLP v2

Un schéma complet

De 8 à 16 champs

- * v1 (Jour 3) : line_id, polygon_ref, transcription, confidence, normalized, ner_spans, pos_tags, lemmas
- * v2 (Jour 4) ajoute : schema_version, pipeline_version, split_hash, topics, relations, coref_chain, graph_node_id, tei_ref

Les huit nouveaux champs v2

Champ	Type	Origine
schema_version	str	Métadonnée pipeline
pipeline_version	str	Métadonnée pipeline
split_hash	str	Split Jour 2
topics	list[dict]	BERTopic Jour 4
relations	list[dict]	Extraction RE Jour 4
coref_chain	str null	Coréférence Jour 4
graph_node_id	str null	Graphe Jour 4
tei_ref	str	Export TEI Jour 4

Valider le contrat v2 : invariants v1

- * pos_tags et lemmas ont la même longueur que normalized.split()
- * Les offsets de ner_spans correspondent exactement au texte extrait

Ces invariants v1 restent vérifiés intégralement dans le contrat v2.

Valider le contrat v2 : nouveaux invariants

- * `schema_version == "2.0"`
- * Chaque topic a `topic_id`, `label`, `weight` ; `weight` $\in [0,1]$
- * Chaque relation a `sujet`, `relation`, `objet` ; `relation` parmi les 5 types connus
- * `tei_ref` se termine par le `line_id` correspondant

PARTIE 8

Protocole de rétroaction HTR

Le fichier JSON des différences

htr_feedback.json : deux objectifs

Réentraînement

Paires (image_region, transcription_corrignée) pour le modèle HTR

Traçabilité scientifique

Documenter chaque correction pour validation

Classer chaque correction

abréviation

~, ^ ou ñ dans la transcription HTR

graphie_uv_ij

u/v présents, CER < 0.3

erreur_majeure

CER > 0.4

autre_graphie

Tout le reste

En attente de validation

- * Jamais injecté directement dans l'entraînement HTR
- * Un humain doit vérifier un échantillon représentatif avant toute injection
- * L'attribut validation_status doit avoir pour valeur « pending »

Le statut ne passe à « validated » qu'après le cycle de validation en 4 étapes.

Le cycle de validation en 4 étapes

- 1 Échantillonnage stratifié : 20 corrections par type (60-80 au total)
- 2 Vérification dans le TEI, avec affichage de l'image via polygon_ref
- 3 Si > 90 % correctes -> statut « validated », sinon affiner le pipeline
- 4 Injection : conversion en paires image_region + texte (PAGE-XML), en respectant les splits

Les livrables attendus en fin de séance

- * Le modèle BERTopic et son rapport de topics
- * Les fichiers TEI-XML validés
- * Le data contract NLP v2
- * Le fichier de rétroaction HTR
- * Le graphe de connaissances exporté en JSON-LD
- * L'interface de requête

Pour aller plus loin

Quelques repères bibliographiques

Topics et interprétation

Blei (2012) ; Chang et al. (2009), Reading Tea Leaves ; Mimno et al. (2011)

Relations et coréférence

Wei et al. (2023), prompting LLM ; Lee et al. (2017), coréférence end-to-end

RAG et TEI

Lewis et al. (2020), RAG ; Clavaud (2019), Initiation au TEI